

Relatório Executivo Projeto Prático Ciência de Dados

Bruno Carvalho *n.º 2120122*

Leonardo Sousa *n.º 2123822*

I. INTRODUÇÃO AO TEMA

No âmbito da unidade curricular de Ciência de Dados, foi proposto o desenvolvimento de um modelo de machine learning utilizando o dataset "New York City Taxi Trips". O objetivo é construir um modelo capaz de prever o preço das viagens de táxi com base em diversas variáveis disponíveis, como distância da viagem, horário do dia, número de passageiros e possíveis condições de tráfego.

II. CONTEXTO E VARIÁVEIS EM USO

O principal objetivo deste projeto é desenvolver um modelo que consiga estimar o valor das tarifas de táxi em Nova York. A tarefa será abordada sob duas perspetivas:

Regressão: Criar um modelo que consiga prever com precisão o valor exato da tarifa para uma determinada viagem.

Classificação: Reformular o problema para classificar as viagens em faixas de preços predefinidas:

- Classe 1: Viagens curtas e de baixo custo (< \$10)
- Classe 2: Viagens de média distância e preço moderado (10–30)
- Classe 3: Viagens longas com tarifas mais elevadas (30–60)
- Classe 4: Tarifas premium (< \$60)

O dataset New York City Yellow Taxi Trip Records contém informações detalhadas sobre viagens de táxi na cidade de Nova York, incluindo dados sobre tempo, distância, localizações de embarque e desembarque, além de informações de pagamento.

III. RESUMO DOS DADOS UTILIZADOS

Os dados utilizados foram constituídos por atributos numéricos e categóricos, totalizando mais de 80.000 registos. Após uma análise inicial, procedeu-se à remoção de outliers, transformação de variáveis categóricas, normalização de variáveis contínuas e criação de uma variável-alvo categorizada (*fare_class*) para tarefas de classificação. Os dados foram divididos em conjuntos de treino, validação e teste.

IV. METODOLOGIA

Foram testados diversos modelos de regressão e classificação, incluindo:

- **Modelos supervisionados:** K-Nearest Neighbors (K-NN), Decision Tree, Linear Regression, Logistic Regression.
- **Modelos ensemble:** Random Forest (bagging) e AdaBoost (boosting).
- **Modelo de Deep Learning:** Rede Neural Multicamada com PyTorch.
- **Clustering:** K-Prototypes (dados mistos) e HDBSCAN (clustering denso).

V. PRINCIPAIS RESULTADOS

- **Regressão:** O **Random Forest Regressor** obteve o melhor desempenho com um RMSE médio de **4.61** e R^2 de **0.86**, superando modelos como AdaBoost e K-NN.
- **Classificação:** O **AdaBoost Classifier** destacou-se com uma **accuracy de 87.38%** e F1-score macro de 81.15%, seguido de perto por Random Forest.
- **Clustering:** O modelo **K-Prototypes** encontrou **5 clusters** com menor custo de distorção (887272.59). O modelo **HDBSCAN**, embora tenha identificado 13 clusters com apenas 10% de ruído, apresentou **baixo desempenho de ARI (0.0049)** e NMI (0.0608), sugerindo fraca correlação com rótulos reais.
- **Deep Learning:** A rede neural obteve um desempenho competitivo ($RMSE = 5.49$, $R^2 = 0.81$), mas com maior tempo de treino e necessidade de ajustes finos.

VI. INSIGHTS E CONCLUSÕES

Modelos ensemble (Random Forest e AdaBoost) demonstraram excelente capacidade de generalização, superando os modelos tradicionais. O K-NN revelou-se sensível à escolha de k e à escala dos dados. A rede neuronal mostrou potencial, mas requer uma maior quantidade de dados e parametrização cuidadosa. Em clustering, K-Prototypes foi mais eficaz na segmentação, enquanto HDBSCAN teve dificuldades em capturar estrutura significativa nos dados.

No geral, em termos práticos o preço de uma viagem de táxi é mais influenciada pela distância percorrida e pelo valor da gorjeta.

VII. RECOMENDAÇÕES FINAIS

- Utilizar **Random Forest** para tarefas de regressão em contextos semelhantes.
- Aplicar **AdaBoost** em problemas de classificação com conjuntos de dados balanceados.
- Refinar o uso de redes neurais com mais dados e regularização para tarefas mais complexas.
- Para análise de perfis de utilizadores, o K-Prototypes é uma opção viável, desde que acompanhado por análise interpretativa.
- Explorar técnicas mais robustas de feature engineering e seleção de variáveis poderá melhorar ainda mais a performance dos modelos.